

HelloSupport — Décisions de design et de développement


Livrable final exigé par la spec ([SPEC.md](#) §3). Ce document explique **chaque** choix de design et de développement du projet.

- **Pendant le projet** : journal type ADR. Chaque jalon ajoute ses entrées D-xx, datées, au moment où la décision est prise (avec ce qu'on savait alors).
- **À la fin (J5)** : consolidation. Synthèse en tête, entrées relues à la lumière des mesures ([BENCH.md](#)), export PDF ([DESIGN DECISIONS.pdf](#)). **Statut : consolidé le 2026-10-02 (v1.8.0), 28 décisions ; D-29 ajoutée le 2026-10-04.**

Format d'une entrée : **Besoin** → **Options envisagées** → **Choix** → **Pourquoi** → **Compromis / limites** → **Compétence visée**. Une décision révisée n'est pas effacée : elle passe en Remplacée par D-yy.

Synthèse (consolidée le 2026-10-02, version 1.8.0)

Ce qui a été construit. Un assistant de dépannage en terminal, 100 % local. Une question en français ou en anglais passe par un **triage** (LLM, sortie JSON contrainte), un **documentaliste** (recherche sémantique : embeddings → Chroma → reranking) et un **technicien**. Selon l'intention, le technicien observe un statut de service **simulé**, interroge une **base SQL d'incidents** en lecture seule (text-to-SQL), ou répond depuis la documentation. Il cite ses sources et sépare l'observé de l'hypothétique. Les outils passent par un **serveur MCP**, l'orchestration par **LangGraph**, les modèles (SLM 4 B / 7 B) sont servis par **LM Studio** sur GPU.




Légende

Style dans le schéma	Nature	Ce que c'est	Boucle ?
 bleu, bord épais	AGENT	Un LLM qui choisit quels outils appeler et avec quels arguments, lit les résultats puis répond (run_agent)	oui : LLM ↔ outils, ≤ 3 appels LLM
 hexagone orange	ROUTEUR	Un seul appel LLM contraint par un schéma JSON, qui choisit 1 des 5 catégories fixes. Sans outil, donc pas un agent	non
 gris, bord pointillé	CODE	Python déterministe, sans LLM	non
 parallélogramme vert	OUTIL MCP	Exposé par le serveur MCP séparé, appelé par les agents	—
 cylindre violet	MODÈLE	LLM servi localement par LM Studio (API OpenAI-compatible)	—

Agent, routeur ou code ? On appelle *agent* un LLM qui **décide lui-même** de ses actions (quels outils, quels arguments) et **boucle** sur leurs résultats jusqu'à pouvoir répondre : c'est le cas du Documentaliste et du Technicien. Le *triage* n'est pas un agent mais un **routeur**. Il fait un seul appel LLM, sans outil, dont la sortie est contrainte à {intent, service} ; c'est le **code** qui en tire le chemin et les outils autorisés (D-17). Le *post-traitement* et les contrôles de la boucle sont du **code** déterministe (D-18, D-22).

Pourquoi aucune boucle entre agents ? Le graphe LangGraph est **linéaire** : triage → documentaliste → technicien (ou triage → technicien pour *history*), et chaque nœud s'exécute une fois par question. Les seules boucles sont **à l'intérieur** de chaque agent, et elles sont bornées (D-18, D-29) :



- **Au plus 3 appels LLM** (MAX_LLM_CALLS). Le dernier est fait sans outils : l'agent finit toujours par répondre en texte.
- **Au plus 3 appels d'outil par étape**, après dédoublonnage. Chaque outil a aussi son budget (search_docs ≤ 2, get_service_status ≤ 1, query_incidents ≤ 2).

- **Outil imposé** : pour malfunction et history, un appel d'outil est exigé. Si le modèle répond sans l'avoir fait, le code rejette cette réponse et relance une fois.
- **Sortie** : la boucle s'arrête dès que le modèle répond en texte sans demander d'outil.

Table de correspondance composant → décision → compétence visée

Composant	Décision retenue	Entrées	Compétence visée
Serving des modèles	LM Studio, API OpenAI-compatible, GPU, Q4_K_M	D-03, D-04	Model-serving platforms ; GPU
Choix des modèles	7 B par défaut, SLM 4 B en option mesurée	D-04, D-25	LLMs and SLMs
Intégration LLM	SDK openai, wrapper qui mesure latence et tokens	D-05	Model integration
Découpage + embeddings	Sections ##, MiniLM multilingue (Sentence Transformers)	D-06, D-07	RAG, embeddings, Hugging Face, PyTorch
Base vectorielle	Chroma embarqué persistant, index par empreinte	D-08	Vector search, vector databases
Reranking	Cross-encoder top-5 → top-3, seuil hors sujet	D-09	Reranking
GPU	torch CUDA, échauffement	D-10	GPU, latency
Outils	Serveur MCP stdio, 3 outils typés, ToolError	D-11, D-12, D-15, D-20	MCP, tool integration, tool calling
Données	SQLite d'incidents, scénarios simulés	D-14	Database systems, SQL engines
Outil SQL	Text-to-SQL en lecture seule, 5 couches de protection	D-13, D-23	Enterprise data agents
Orchestration	LangGraph : triage → documentaliste → technicien, branche history	D-16	Orchestration, LangGraph
Décision d'outil	Routeur par sortie structurée + politique imposée par le code	D-17, D-24	AI agents, intelligent workflows
Fiabilité	Boucle bornée, dedup, required vérifié, post-traitement	D-18, D-22	Reliability, production-grade
État et traces	TypedDict + reducers, trace JSON horodatée	D-19	State management
Validation	6 cas exécutables, bench, vérifications déterministes	D-21, D-28	Prototype → production
Mesures	Latence à chaud/froid, débit à concurrence 1/4, coût estimé	D-26	Latency, throughput, cost
Code	Modules à responsabilité unique, frontière MCP	D-02, D-27	Software architecture, Python
Cadre	100 % local, 0 €	D-01	Cost

Ce que les mesures ont appris (les décisions qui en découlent sont marquées « suite à un échec mesuré ») :

1. **Les petits modèles ne décident pas seuls d'observer** : laissés libres de choisir, 0/3 pour le 4 B comme pour le 7 B. Un routeur étroit à sortie contrainte, puis une politique imposée par le code, donnent 18/18 avec le 7 B (D-17).
2. **Une contrainte d'API n'est pas une garantie** : tool_choice="required" n'est pas imposé par LM Studio, et le modèle a inventé un statut. Le code vérifie et relance (D-18). La démo finale montre ce garde-fou en action.
3. **Le modèle hallucine quand il « raconte » l'étape suivante** au lieu de la faire (C4). Faire émettre toutes les requêtes d'un coup supprime le problème (D-23).
4. **Ce que le code sait, le code le dit** : statut simulé, absence d'action, liste des sources valides (D-22).
5. **Un réglage de prompt se mesure sur des données tenues à l'écart** : un ajout d'exemples a amélioré le SLM et dégradé le 7 B (D-24).
6. **Le coût est porté par le contexte, pas par la taille du modèle** : ~2 700 tokens en entrée pour ~370 en sortie (D-26).
7. **Les vérifications automatiques ont aussi des bugs** : deux d'entre elles étaient fausses (D-21). D'où l'archivage des réponses complètes pour relecture.

Limites assumées : 3 fiches, 14 incidents, 6 cas, une machine, température 0. Aucune mesure n'est statistiquement solide. SQLite n'est pas un moteur d'entreprise. LM Studio n'est pas un serveur de production. Le SLM invente

encore des sources quand un outil échoue. Hors périmètre : systèmes distribués, scale réel, leadership (cf. [SPEC.md](#) §7 et §10).

Index

#	Décision	Jalon	Statut	Compétence visée
D-01	100 % local, aucune API cloud payante	cadrage	Acceptée	Cost, model serving
D-02	Python 3.12 + uv + package installable avec CLI	J0	Acceptée	Python, software architecture
D-03	LM Studio comme plateforme de serving locale	J0	Acceptée	Model-serving platforms
D-04	Choix des modèles : Qwen3-4B-Instruct-2507 (SLM) et Qwen2.5-7B-Instruct, Q4_K_M	J0	Acceptée, confirmée par D-25	LLMs & SLMs, GPU
D-05	Client LLM : SDK openai via l'endpoint OpenAI-compatible, mince wrapper maison	J0	Acceptée	Model integration, latency/cost
D-06	Découpage des fiches par section ##, citation doc_id#section	J1	Acceptée	RAG, semantic retrieval
D-07	Embeddings : paraphrase-multilingual-MiniLM-L12-v2 (Sentence Transformers)	J1	Acceptée	Embeddings, Hugging Face
D-08	Store vectoriel : Chroma embarqué persistant, index reconstruit sur empreinte	J1	Acceptée	Vector search, vector databases
D-09	Reranking : cross-encoder mmarco-mMiniLMv2-L12-H384-v1, top-5 → top-2, seuil hors sujet	J1	Acceptée	Reranking
D-10	Inférence embeddings/reranker sur GPU (torch CUDA), échauffement au chargement	J1	Acceptée	GPU, PyTorch, latency
D-11	MCP : serveur d'outils séparé, stdio, SDK mcp v2, vérifié avec MCP Inspector	J2	Acceptée	MCP, tool integration
D-12	Contrats d'outils typés (Literal → enum), ToolError explicites	J2	Acceptée	Tool calling, reliability
D-13	Outil SQL lecture seule : 5 couches (regex, LIMIT, mode=ro, authorizer, timeout)	J2	Acceptée	Enterprise data agents, SQL engines
D-14	SQLite d'incidents générée (dates relatives), scénarios de statut JSON simulés	J2	Acceptée	Database integration, data analysis
D-15	Chargement du RAG en thread au démarrage du serveur MCP	J2	Acceptée	Latency
D-16	Orchestration LangGraph : triage → documentaliste → technicien, branche history	J3	Acceptée	Orchestration, LangGraph
D-17	Triage par sortie structurée + politique d'outils imposée par le code	J3	Acceptée (suite à un échec mesuré)	AI agents, intelligent workflows
D-18	Boucle d'agent bornée : budgets, dernier appel sans outils, dédup, required vérifié	J3	Acceptée	Reliability, workflow execution
D-19	État partagé TypedDict (reducers) + trace JSON horodatée avec métriques	J3	Acceptée	State management, latency/cost
D-20	Client MCP hôte avec le SDK mcp direct (ToolBox), sans adaptateur LangChain	J3	Acceptée	MCP, tool integration
D-21	Validation : 6 cas exécutables, vérifications déterministes, bench avec réponses complètes	J4	Acceptée	Prototype → production, evaluation
D-22	Post-traitement déterministe : citations normalisées, mention de simulation	J4	Acceptée (suite à un échec mesuré)	Reliability
D-23	Questions data : toutes les requêtes SQL dans la même étape	J4	Acceptée (suite à un échec mesuré)	Enterprise data agents

#	Décision	Jalon	Statut	Compétence visée
D-24	Triage : règles + exemples, validé sur paraphrases tenues à l'écart (12/12)	J4	Acceptée (suite à un échec mesuré)	Evaluate AI tech, SLMs
D-25	ADR : modèle par défaut = 7 B (18/18) ; SLM plus rapide mais invente des sources	J5	Acceptée	LLMs & SLMs, latency/cost, evaluate → plan
D-26	Méthode de mesure : latence à chaud/froid, débit à concurrence 1/4, coût estimé	J5	Acceptée	Latency, throughput, cost
D-27	Structure du code : modules à responsabilité unique, frontière MCP	J5	Acceptée	Software architecture, Python
D-28	Stratégie de tests : unitaires hors ligne, intégration modèles, bench système	J5	Acceptée	Production-grade, reliability
D-29	Agents (boucle LLM ↔ outils) vs routeur (triage) vs code ; graphe linéaire, aucune boucle entre agents	doc	Acceptée	AI agents, orchestration

D-01 — 100 % local, aucune API cloud payante

- **Date** : 2026-10-02 · **Jalon** : cadrage (décision utilisateur)
- **Besoin** : pratiquer LLM, agents et RAG sans frais, sans compte, et sans données qui sortent de la machine.
- **Options** : (a) API cloud (OpenAI, Anthropic...), (b) modèles locaux, (c) mixte : local par défaut, cloud pour comparer.
- **Choix** : (b) 100 % local. Le coût cloud est **estimé** dans le benchmark (tokens mesurés × prix publics), sans compte.
- **Pourquoi** : coût nul, aucun secret à gérer, reproductible hors ligne. Surtout, ça oblige à traiter le **serving** et les **SLM**, deux compétences visées que l'API cloud aurait masquées.
- **Compromis** : les modèles locaux (4–7 B) sont nettement moins bons que les modèles cloud de pointe en tool calling et en text-to-SQL. Les résultats qualitatifs ne sont donc pas représentatifs d'un déploiement avec un grand modèle. Il faut le dire clairement.
- **Compétence visée** : Cost, model serving.

D-02 — Python 3.12 + uv + package installable avec CLI

- **Date** : 2026-10-02 · **Jalon** : J0
- **Besoin** : un projet qui s'installe et se lance en une commande, avec une version visible (convention du projet).
- **Options** : scripts isolés + requirements.txt ; Poetry ; uv + pyproject.toml.
- **Choix** : uv + pyproject.toml (layout src/), entrée CLI hello-support, version unique dans hello_support/__init__.py (__version__) et lue dynamiquement par le build.
- **Pourquoi** : uv est déjà installé, très rapide, et gère le lockfile et le venv. Le layout src/ évite d'importer le code sans l'avoir installé. Une seule source de vérité pour la version.
- **Compromis** : torch avec CUDA doit venir de l'index PyTorch (cu124), pas de PyPI, d'où une config d'index dans pyproject.toml. Ajouté à J1, quand torch devient nécessaire.
- **Compétence visée** : Python, software architecture.

D-03 — LM Studio comme plateforme de serving locale

- **Date** : 2026-10-02 · **Jalon** : J0
- **Besoin** : servir un LLM local derrière une API standard, avec le GPU, et pouvoir changer de modèle sans toucher au code.
- **Options** : (a) LM Studio (déjà installé, CLI 1ms, serveur OpenAI-compatible), (b) Ollama (non installé), (c) vLLM (débit élevé, mais Linux/WSL seulement et lourd sur 8 Go), (d) transformers en direct dans le process.
- **Choix** : (a) LM Studio, serveur sur http://localhost:1234/v1.

- **Pourquoi** : déjà en place, il gère le téléchargement (`lms get`), l'offload GPU et la quantification GGUF. Il expose l'API **OpenAI-compatible** avec *tool calling*. Le code applicatif ne dépend donc que d'un **contrat d'API**, pas d'un fournisseur. C'est exactement la séparation « application / plateforme de serving » visée.
- **Compromis** : outil desktop, pas un serveur de prod. Pas de batching continu ni de mesure de débit sérieuse : vLLM est noté dans « pour aller plus loin ». Le serveur doit tourner (`lms server start`) avant de lancer le programme.
- **Compétence visée** : Model-serving platforms.

D-04 — Choix des modèles

- **Date** : 2026-10-02 · **Jalon** : J0 · **Révisable à J5** (mesures)
- **Besoin** : un **SLM** (3–4 B) capable d'appeler des outils, et un modèle plus gros (7 B) de référence, les deux tenant dans **8 Go de VRAM** (RTX 2070 Super).
- **Options SLM** : Qwen2.5-3B-Instruct ; **Qwen3-4B-Instruct-2507** ; Llama-3.2-3B-Instruct ; Phi-4-mini (3,8 B) ; Gemma-3-4B (déjà présent sous la forme `translatagemma`, spécialisé en traduction et sans tool calling natif fiable).
- **Options 7 B** : qwen2.5-coder-7b-instruct (déjà présent) ; **Qwen2.5-7B-Instruct** ; Llama-3.1-8B-Instruct.
- **Choix** :
 - SLM = `qwen/qwen3-4b-2507` en **Q4_K_M** (~2,5 Go) ;
 - 7 B = `qwen2.5-7b-instruct` en **Q4_K_M** (~4,7 Go).
- **Pourquoi** :
 - Qwen3-4B-Instruct-2507 est entraîné pour le tool calling. C'est la variante « non-thinking », donc sans bloc de raisonnement à filtrer, avec des réponses plus courtes et une latence plus basse. Il est multilingue (questions en français) et figure parmi les meilleurs 4 B publics en appel de fonctions à sa sortie.
 - Pour le 7 B, prendre la **même famille** (Qwen) isole l'effet de la **taille** dans la comparaison. La version *Instruct* est préférée à *Coder* pour du dialogue et du diagnostic. C'est le modèle nommé dans la demande utilisateur.
 - **Q4_K_M** est le compromis standard qualité/taille. Le 7 B tient entièrement en VRAM (~4,7 Go + KV-cache), avec de la marge pour les modèles d'embedding et de reranking (~0,5 Go). Q8 (~8 Go) ne tiendrait pas.
- **Compromis** : la quantification 4 bits dégrade un peu la qualité, surtout sur le SQL. Deux familles différentes auraient permis une comparaison plus large, mais moins lisible. Les deux modèles ne sont pas chargés en même temps : LM Studio les charge à la demande (JIT), et le premier appel inclut donc un temps de chargement. Il est exclu des mesures (échauffement).
- **Mise en œuvre (J0)** : `lms get "qwen/qwen3-4b-2507@q4_k_m" -y` (staff pick LM Studio). Qwen2.5-7B-Instruct n'est pas un staff pick : téléchargé depuis Hugging Face avec `lms get "https://huggingface.co/lmstudio-community/Qwen2.5-7B-Instruct-GGUF@Q4_K_M" -y`.
- **Constat J0** (`hello-support smoke`, températures 0, après échauffement) : les deux modèles émettent un appel `get_time({"timezone": "Europe/Brussels"})` valide. SLM : `hello` 0,10 s, tool call 0,37 s (177 → 23 tokens). 7 B : 0,10 s et 0,55 s (193 → 23 tokens). Mesures ponctuelles, pas encore un benchmark (J5).
- **Compétence visée** : LLMs & SLMs, GPU.

D-05 — Client LLM : SDK `openai` + wrapper maison minimal

- **Date** : 2026-10-02 · **Jalon** : J0
- **Besoin** : appeler le modèle avec ou sans outils, et récupérer contenu, appels d'outils, tokens et latence.
- **Options** : (a) SDK `openai` pointé sur `localhost:1234`, (b) `langchain-openai` (ChatOpenAI), (c) `httpx` brut.
- **Choix** : (a). Un module `llm.py` de quelques dizaines de lignes renvoie un résultat normalisé (`content`, `tool_calls`, `prompt_tokens`, `completion_tokens`, `latency_s`, `model`).
- **Pourquoi** : on voit exactement ce qui part et revient sur le fil, ce qui est pédagogique et utile pour mesurer. Le SDK est stable et typé. LangGraph n'impose pas LangChain pour les nœuds : un nœud est une fonction Python. Ça limite les couches d'abstraction.

- **Compromis** : on réimplémente un peu de plomberie que ChatOpenAI + bind_tools offrent. Si J3 montre que c'est trop coûteux, on basculera sur langchain-openai, en ajoutant une entrée qui remplace celle-ci.
- **Compétence visée** : Model integration, latency/cost.

D-06 — Découpage des fiches par section

- **Date** : 2026-10-02 · **Jalon** : J1
- **Besoin** : retrouver un passage précis et le **citer** (« postgres_connection.md, section Service status »), comme l'exige la réponse attendue.
- **Options** : (a) un document entier par vecteur, (b) découpe à taille fixe (N tokens avec chevauchement), (c) découpe par structure (titres ##).
- **Choix** : (c). Une section = un chunk, identifié doc_id#section. Le texte embarqué est préfixé par le titre de la fiche (« PostgreSQL: application cannot connect - Checks ») pour que la section garde son contexte.
- **Pourquoi** : les fiches sont courtes et déjà structurées (Symptoms / Checks / Service status / Limits). La découpe structurelle donne des citations stables et lisibles. La découpe fixe couperait au milieu d'une liste de vérifications.
- **Compromis** : ça suppose des documents bien structurés. Sur un vrai corpus d'entreprise (PDF, wikis), il faudrait une découpe hybride (structure + taille maximale + chevauchement).
- **Compétence visée** : RAG, semantic retrieval.

D-07 — Modèle d'embeddings

- **Date** : 2026-10-02 · **Jalon** : J1
- **Besoin** : encoder des questions **en français ou en anglais** et des fiches en anglais dans un même espace vectoriel, localement, sur 8 Go de VRAM partagés avec le LLM.
- **Options** : all-MiniLM-L6-v2 (anglais seulement) ; paraphrase-multilingual-MiniLM-L12-v2 (50+ langues, 118 M paramètres, dim 384) ; multilingual-e5-base / bge-m3 (meilleurs, mais 2 à 5 fois plus gros) ; nomic-embed-text servi par LM Studio (déjà présent).
- **Choix** : paraphrase-multilingual-MiniLM-L12-v2 via Sentence Transformers (Hugging Face Hub, sans compte). Vecteurs normalisés, similarité cosinus.
- **Pourquoi** : c'est le candidat proposé par le document initial. Il est multilingue (la requête FR « connexion refusée » retrouve bien la fiche EN), léger (~0,5 Go en VRAM) et rapide. Le passer par Sentence Transformers plutôt que par LM Studio fait pratiquer **PyTorch / Hugging Face** directement.
- **Compromis** : la qualité est modeste. Le cosinus brut sépare mal (0,46 à 0,52 pour des sections utiles comme pour des sections nginx hors sujet, cf. BENCH J1). C'est précisément ce qui justifie le reranker (D-09). Un modèle e5/bge serait l'amélioration naturelle.
- **Compétence visée** : Embeddings, Hugging Face.

D-08 — Store vectoriel : Chroma embarqué

- **Date** : 2026-10-02 · **Jalon** : J1
- **Besoin** : stocker et interroger les vecteurs (top-k par similarité) sans serveur à administrer.
- **Options** : (a) NumPy en mémoire (proposition initiale : cosinus brute-force), (b) **Chroma** embarqué (PersistentClient, index HNSW), (c) sqlite-vec (extension SQLite), (d) PostgreSQL + pgvector (WSL/Docker), (e) FAISS.
- **Choix** : (b) Chroma 1.5, collection kb_sections en espace **cosinus**, persistée dans .chroma/ (gitignoré). Les embeddings sont calculés par notre code et passés à Chroma, qui ne choisit pas le modèle. L'index n'est reconstruit que si l'**empreinte** (hash du modèle + du contenu des sections) change.
- **Pourquoi** : c'est une vraie base vectorielle (index ANN, métadonnées, persistance), installée par pip, sans Docker. Elle couvre la compétence « base vectorielle » à moindre coût. Fournir nos propres vecteurs garde la maîtrise du modèle (D-07) et permet de le changer sans dépendre des fonctions d'embedding intégrées de Chroma. Avec l'empreinte, on évite un recalcul à chaque démarrage tout en garantissant que l'index n'est jamais périmé.

- **Compromis** : à 12 vecteurs, un index ANN n'apporte **aucun** gain : le brute-force NumPy serait aussi rapide. Le choix est pédagogique, et il faut le dire. Chroma ajoute beaucoup de dépendances. pgvector serait plus proche d'un contexte « IA + base de données » : il est placé en « pour aller plus loin ». Repli prévu : cosinus NumPy si Chroma posait problème (ça n'a pas été le cas).
- **Compétence visée** : Vector search, vector databases.

D-09 — Reranking par cross-encoder

- **Date** : 2026-10-02 · **Jalon** : J1
- **Besoin** : améliorer l'ordre des passages renvoyés à l'agent (seulement 2, donc le classement compte), et détecter qu'**aucun** passage ne correspond.
- **Options** : (a) pas de reranking, (b) **cross-encoder** Sentence Transformers, (c) reranker LLM (demander au modèle de classer), (d) bge-reranker-v2-m3 (plus précis, ~570 M paramètres).
- **Choix** : (b) cross-encoder/mmarco-mMiniLMv2-L12-H384-v1 (multilingue, léger). Recherche vectorielle top-5, rerank des 5 paires (question, passage), top-2 conservé. Chaque hit garde son rang vectoriel d'origine pour montrer l'effet du reranking. Seuil `RELEVANCE_THRESHOLD` = -5 sur le score du cross-encoder : en dessous, le passage est marqué « hors sujet ».
- **Pourquoi** : c'est le schéma classique *retrieve & rerank*. Le bi-encoder est rapide mais grossier, le cross-encoder lit la question et le passage ensemble et classe mieux. Mesuré (BENCH J1) : sur « connexion refusée postgres », la section *Symptoms* passe de la 5^e à la 2^e place devant deux sections nginx. Sur une question hors base (Kafka), tous les scores tombent $\leq -9,2$ alors que les passages utiles sont $\geq -4,3$. Ce signal est bien plus discriminant que le cosinus (0,12–0,21). Un reranker LLM aurait coûté un appel au modèle par requête.
- **Compromis** : environ 0,1–0,3 s de plus par requête. Le seuil est **empirique** et calibré sur 4 requêtes : c'est un filtre grossier, pas une garantie de précision. Il faudrait l'étalonner sur un jeu de questions (voir « pour aller plus loin » : évaluation RAG).
- **Révision (J3)** : `search_docs` renvoie le **top-3** (au lieu du top-2). Avec 2 passages, le reranker plaçait « Limits » en tête et la section « Service status » disparaissait du contexte.
- **Compétence visée** : Reranking.

D-10 — Inférence sur GPU et échauffement

- **Date** : 2026-10-02 · **Jalon** : J1
- **Besoin** : utiliser le GPU disponible et mesurer une latence de requête représentative.
- **Options** : CPU seulement ; GPU via torch CUDA ; embeddings servis par LM Studio.
- **Choix** : torch **2.6.0+cu124** tiré de l'index PyTorch (configuré dans `pyproject.toml`, car PyPI ne fournit que la version CPU sous Windows). Device choisi automatiquement (`cuda` sinon `cpu`) et affiché. Une requête d'**échauffement** est faite au chargement du Retriever.
- **Pourquoi** : le GPU est là (RTX 2070 Super). Les deux petits modèles y tiennent (~1 Go) à côté du LLM servi par LM Studio. Mesuré : la première requête coûte ~2,9 s (initialisation des kernels CUDA) contre ~0,5 s ensuite. L'échauffement sort ce coût unique de la latence par question.
- **Compromis** : téléchargement de torch CUDA lourd (~2,5 Go), import de `sentence_transformers` lent (~15 s à froid sous Windows), chargement total ~27 s. Acceptable parce que payé une fois par session du serveur d'outils (J2). Sur CPU, le projet fonctionne aussi, simplement plus lentement.
- **Compétence visée** : GPU, PyTorch, latency.

D-11 — MCP : serveur d'outils séparé, transport stdio, SDK Python v2

- **Date** : 2026-10-02 · **Jalon** : J2
- **Besoin** : exposer les outils aux agents par un **protocole standard**, pour pouvoir les tester seuls, les réutiliser par un autre client (Inspector, IDE, autre agent), et les déplacer sans toucher au code des agents.
- **Options** : (a) fonctions Python appelées directement par les agents, (b) API REST maison, (c) **MCP** en stdio (sous-processus local), (d) MCP en *streamable HTTP* (serveur réseau).

- **Choix** : (c) avec le SDK officiel mcp **2.2** (MCPServer, nouveau nom de FastMCP dans la v2). Point d'entrée `hello-support-mcp`. L'hôte lancera le serveur comme sous-processus (J3). Les tests utilisent le même serveur **en mémoire** via `mcp.Client(server)`.
- **Pourquoi** : MCP est l'une des compétences visées (intégration d'outils d'entreprise pour des agents). Le studio n'a besoin d'aucun port ni d'aucune auth et suffit en local. Le schéma JSON des entrées est généré depuis les annotations Python. Vérifié avec **MCP Inspector** (`npx @modelcontextprotocol/inspector --cli hello-support-mcp --method tools/list` puis `tools/call` pour chacun des 3 outils).
- **Compromis** : un sous-processus par session et un protocole de plus à déboguer. Le SDK v2 est récent : les exemples en ligne (FastMCP, `inputSchema` en camelCase) ne s'appliquent plus tels quels. L'Inspector en mode CLI passe mal les arguments `-m module`, d'où le point d'entrée dédié. Le transport HTTP (premier pas « distribué ») est laissé à « pour aller plus loin ».
- **Compétence visée** : MCP, tool integration.

D-12 — Contrats d'outils : types stricts, erreurs explicites

- **Date** : 2026-10-02 · **Jalon** : J2
- **Besoin** : le modèle **propose** des appels qui peuvent être faux (service inconnu, SQL invalide, requête vide). Ces erreurs doivent être refusées proprement et rester exploitables par le modèle.
- **Options** : validation dans chaque agent ; validation côté serveur d'outils ; les deux.
- **Choix** : validation **côté serveur**, par les types : `service_name: Literal["postgres", "nginx", "redis"]` produit un enum dans le schéma MCP, que le modèle voit et que Pydantic vérifie. Les erreurs métier lèvent `ToolError`, rendu au client en `is_error=true` avec un message clair (ex. « unknown service », « SQL rejected: only SELECT queries are allowed »). Les descriptions d'outils (docstrings) expliquent le format de sortie et l'usage, par exemple `relevant=false`.
- **Pourquoi** : un seul endroit fait foi, quel que soit le client. L'erreur renvoyée au modèle lui permet de **se corriger une fois** (J3) au lieu de planter. Le schéma enum réduit les erreurs à la source, ce qui est important pour un SLM.
- **Compromis** : les messages de validation Pydantic sont verbeux pour un petit modèle. Le serveur ne connaît pas les **limites d'appels** : c'est le rôle de l'orchestrateur (J3).
- **Compétence visée** : Tool calling, reliability.

D-13 — Outil SQL en lecture seule : défense en profondeur

- **Date** : 2026-10-02 · **Jalon** : J2
- **Besoin** : laisser l'agent **écrire du SQL** (text-to-SQL, comme un « enterprise data agent ») sans qu'il puisse modifier ou exfiltrer quoi que ce soit, ni bloquer la base.
- **Options** : (a) outil paramétré (`get_incidents(service, days)`), sans SQL libre ; (b) SQL libre avec un filtre regex ; (c) SQL libre avec **plusieurs couches indépendantes**.
- **Choix** : (c), dans `sql_guard.py` :
 1. contrôle statique : une seule instruction, qui commence par `SELECT/WITH`, sans mot-clé d'écriture ou d'administration (`DELETE, PRAGMA, ATTACH, load_extension...`) ;
 2. requête enveloppée : `SELECT * FROM (<sql>) LIMIT 51`, puis tronquée à 50 lignes avec un drapeau `truncated` ;
 3. connexion SQLite `mode=ro` : le moteur refuse toute écriture ;
 4. **authorizer** SQLite : seules les actions `SELECT/READ/FUNCTION/RECURSIVE` sont permises ;
 5. **progress handler** : la requête est abandonnée au-delà de 2 s.

Le schéma de la table et un exemple de filtre de date sont dans la description de l'outil. - **Pourquoi** : (a) serait plus sûr, mais ne pratique pas le text-to-SQL, qui est le cœur d'un data agent. Une regex seule se contourne : chaque couche couvre les angles morts des autres, et les couches 3–4 sont garanties par le moteur, pas par notre code. Les erreurs SQL (colonne inconnue...) sont renvoyées telles quelles pour que le modèle corrige sa requête. Testé : `DELETE, SELECT 1; DROP,,, PRAGMA, ATTACH, load_extension` sont refusés ; la limite de lignes est appliquée (`tests/test_sql_guard.py`). - **Compromis** : la regex peut refuser une requête légitime contenant un de ces mots

dans une chaîne (ex. `summary LIKE '%update%'`). C'est acceptable ici, à corriger avec un vrai parseur SQL (`sqlglot`) si besoin. Rien n'empêche une requête **fausse mais valide** : la justesse est évaluée en J4 (cas C4). Sur une vraie base d'entreprise, il faudrait en plus un rôle SQL dédié en lecture seule et des vues restreintes. - **Compétence visée** : Enterprise data agents, SQL engines.

D-14 — Données : SQLite d'incidents générée, scénarios JSON simulés

- **Date** : 2026-10-02 · **Jalon** : J2
- **Besoin** : des données structurées réalistes pour les questions d'analyse (« combien d'incidents postgres ces 30 derniers jours ? ») et des états de service **simulés** et contrôlables pour les cas C1/C2/C6.
- **Options données** : PostgreSQL réel (WSL/Docker), DuckDB, **SQLite** (stdlib). **Options statuts** : interroger de vrais services ; un fichier JSON de scénarios.
- **Choix** : table `incidents` (14 lignes : service, date, sévérité, résumé, résolu) générée par `seed_incidents()` avec des dates **relatives à aujourd'hui**. Le fichier `data/incidents.db` est gitignoré et créé à la première utilisation. Les statuts viennent de `scenarios.json` (`stopped`, `running`, `redis_down`, `tool_error`), choisis par `HS_SCENARIO` (bientôt `--scenario`). Chaque réponse porte `simulated: true` et le nom du scénario.
- **Pourquoi** : SQLite est dans la stdlib, sans serveur, et c'est un vrai moteur SQL (dates, agrégats, CTE récursives, `authorize`). Avec des dates relatives, « les 30 derniers jours » a toujours la même réponse attendue, ce qui rend le cas C4 vérifiable. Les scénarios rendent le comportement **déterministe** et permettent de simuler une panne d'outil (C6). Comme rien de réel n'est touché, aucune action dangereuse n'est possible.
- **Compromis** : SQLite n'est pas un moteur d'entreprise : pas de rôles, ni de concurrence d'écriture ni de plan distribué. 14 lignes ne testent pas la performance. PostgreSQL + pgvector est en « pour aller plus loin ».
- **Compétence visée** : Database integration, data analysis.

D-15 — Chargement du RAG en arrière-plan dans le serveur MCP

- **Date** : 2026-10-02 · **Jalon** : J2
- **Besoin** : le Retriever met ~30 s à charger. Si on le charge avant de démarrer le serveur, le handshake MCP dépasse le délai du client (15 s par défaut pour l'Inspector).
- **Options** : chargement au démarrage (bloquant) ; chargement paresseux au premier appel ; **chargement dans un thread au démarrage**, le premier `search_docs` attendant la fin.
- **Choix** : le thread. Le handshake est immédiat, les outils `get_service_status` et `query_incidents` sont disponibles tout de suite, et `search_docs` attend au plus 180 s. Les erreurs de chargement sont renvoyées en `ToolError`.
- **Pourquoi** : en général le documentaliste appelle `search_docs` en premier, après un appel LLM : le chargement se fait pendant ce temps-là au lieu de s'ajouter à la latence.
- **Compromis** : un peu de concurrence à gérer (un Event). Mesuré via l'Inspector : un appel `search_docs` à froid prend ~54 s de bout en bout (démarrage npx + process + chargement). Cela reste payé une fois par session.
- **Compétence visée** : Latency.

D-16 — Orchestration : LangGraph `StateGraph`, nœuds = fonctions Python

- **Date** : 2026-10-02 · **Jalon** : J3
- **Besoin** : enchaîner des étapes (triage → recherche → diagnostic), avec des branches conditionnelles, un état partagé et un arrêt garanti.
- **Options** : (a) une boucle Python « à la main », (b) **LangGraph** (graphe d'états), (c) un agent ReAct unique (`create_react_agent`) qui décide de tout, (d) CrewAI / AutoGen (multi-agent conversationnel).
- **Choix** : (b) LangGraph 1.2, graphe `START` → `triage` → `documentalist` → `technician` → `END`, avec une **arête conditionnelle** : les questions d'historique (`history`) vont directement au technicien, sans recherche

documentaire. Une autre fait sortir vers END si le documentaliste échoue. Les nœuds sont de simples fonctions async : LangChain n'est pas nécessaire (D-05). `recursion_limit=10` sert de filet de sécurité.

- **Pourquoi** : c'est le framework d'agents visé. Il sépare clairement le **workflow défini par le code** (structure, branches, politique d'outils) des **décisions du modèle** (arguments d'outils, SQL, rédaction), ce que le document initial recommandait déjà. Un agent ReAct unique laisse tout au modèle, ce qui s'est révélé peu fiable avec des modèles 4–7 B (D-17).
- **Compromis** : pour 3 nœuds linéaires, LangGraph est presque surdimensionné. Sa valeur apparaît avec les branches, les checkpoints et le human-in-the-loop (« pour aller plus loin »). Le chargement de LangGraph ajoute des dépendances.
- **Compétence visée** : Orchestration, LangGraph.

D-17 — Triage par sortie structurée + politique d'outils appliquée par le code

- **Date** : 2026-10-02 · **Jalon** : J3 · **Décision issue d'un échec mesuré**
- **Besoin** : le technicien doit **observer** (appeler `get_service_status`) quand une panne est signalée, et ne pas le faire pour une question documentaire.
- **Constat** : la première version laissait ce choix au modèle (`tool_choice="auto"`, règles dans le prompt). Mesuré sur l'entrée réelle du technicien : **0/3** appels pour Qwen2.5-7B **et** pour Qwen3-4B, quelle que soit la mise en page (rappel en fin de message, sans brief, question en dernier). Les deux modèles répondaient au conditionnel (« si le service est arrêté... ») puisque la fiche décrit les deux cas. Le 7 B allait jusqu'à dire à l'utilisateur d'appeler `get_service_status` lui-même.
- **Options** : (a) prompt engineering supplémentaire ; (b) appel d'outil systématique ; (c) **routeur** : un appel LLM court qui classe l'intention en JSON contraint, puis une politique d'outils décidée par le code ; (d) un modèle plus gros.
- **Choix** : (c). Nœud triage : `response_format JSON Schema strict → {intent: malfunction|history|documentation|out_of_scope|vague, service}`. Le code applique `TECHNICIAN_POLICY` :
 - `malfunction` → seul `get_service_status` est proposé, un appel est **exigé** ;
 - `history` → `query_incidents` est **exigé**, le modèle écrit le SQL ;
 - `documentation` → aucun outil ;
 - `out_of_scope / vague` → aucun outil et une consigne explicite (dire la limite / poser une question).

Une panne sans service connu est requalifiée en vague. - **Pourquoi** : mesuré sur 6 questions types, le triage coûte ~0,3 s (après chargement) et classe correctement les cas clés. Qwen2.5-7B : 4/6, les deux « erreurs » (Kafka → vague, « ça marche pas » → panne sans service) aboutissant quand même au bon comportement. Qwen3-4B : 4/6, mais il a confondu « panne + que vérifier ? » avec documentation, corrigé par une précision dans le prompt. Le modèle décide toujours, mais **sur une tâche étroite et contrainte**, et le code garantit les conséquences. C'est un schéma *router + policy* courant en production. - **Compromis** : un appel LLM de plus par requête. La classification peut se tromper, et l'erreur se propage (pas de retour arrière). Les 5 intentions sont figées dans le code. -

Compétence visée : AI agents, intelligent workflows.

D-18 — Boucle d'agent bornée et garde-fous mesurés

- **Date** : 2026-10-02 · **Jalon** : J3
- **Besoin** : aucune boucle infinie, un coût borné, des erreurs d'outil qui ne font pas planter le programme, et pas d'observation inventée.
- **Choix** (`agents.run_agent`, partagé par les deux agents) :
 - 3 appels LLM au maximum par agent. Le **dernier appel est fait sans outils**, ce qui force une réponse texte ;
 - budgets par outil : `search_docs ≤ 2`, `get_service_status ≤ 1`, `query_incidents ≤ 2`. Un dépassement renvoie au modèle un message d'erreur, pas une exception ;
 - **déduplication** des appels identiques et **3 appels au plus par étape**. Raison mesurée : le 7 B, forcé d'appeler un outil qui échoue (scénario `tool_error`), a émis **46 appels identiques** en 1 024 tokens (18 s) ;

- `max_tokens` = 300 pour une étape avec outils, 700 pour une réponse finale ;
- `tool_choice="required"` **vérifié par le code** : LM Studio ne l'impose pas strictement. Une fois, le 7 B a répondu en texte et **inventé** un statut « en cours d'exécution » sans appeler l'outil. Une réponse sans l'observation exigée est donc rejetée et le modèle relancé une fois ;
- arguments JSON invalides et outils non autorisés : refusés avec un message ;
- timeout HTTP des appels LLM (120 s) et des appels d'outils (240 s).
- **Pourquoi** : on ne fait pas confiance au modèle pour s'arrêter ou pour respecter une contrainte d'API. Chaque garde-fou ci-dessus vient d'un comportement **observé** pendant J3.
- **Compromis** : les limites sont des choix de périmètre, pas des optimums. Une réponse rejetée coûte un appel LLM. La qualité du raisonnement n'est pas garantie : au cas C4, le 7 B a calculé `MAX(resolved)` et en a pourtant conclu « le dernier n'est pas résolu ». C'est exact par hasard, mais pas déduit du résultat (évaluation J4).
- **Compétence visée** : Reliability, workflow execution.

D-19 — État partagé explicite et trace JSON

- **Date** : 2026-10-02 · **Jalon** : J3
- **Besoin** : savoir à tout moment ce que chaque étape a vu et décidé, rejouer et mesurer une exécution.
- **Choix** : State (TypedDict) : `question` (jamais modifiée), `model`, `scenario`, `route`, `evidence` (passages pertinents uniquement, dédoublés), `brief`, `observations`, `counters`, `status`, `errors` et `trace` (ces deux derniers avec un `reducer operator.add` : les nœuds **ajoutent**, n'écrasent pas), `answer`. Chaque événement (`llm`, `tool_call`, `tool_result`, `limit`, `error`) est horodaté, affiché en direct et écrit dans `runs/<horodatage>.json` avec les métriques (durée totale, appels et temps LLM, tokens in/out, temps des outils). Le dossier `runs/` est gitigné.
- **Pourquoi** : les mises à jour passent explicitement par les retours des nœuds, ce qui est le modèle de LangGraph. Afficher les **décisions observables** (outil, arguments, résultat) plutôt qu'un « raisonnement » interne suit la recommandation du document initial. La trace a servi à diagnostiquer chacun des problèmes de D-17/D-18.
- **Compromis** : l'état vit en mémoire le temps d'une requête. Il n'y a pas de reprise après crash (checkpointing LangGraph = « pour aller plus loin »). La trace contient les textes complets, ce qui pourrait poser problème avec des données sensibles en contexte réel.
- **Compétence visée** : State management, latency/cost.

D-20 — Client MCP côté hôte : SDK `mcp` direct plutôt que `langchain-mcp-adapters`

- **Date** : 2026-10-02 · **Jalon** : J3
- **Besoin** : lancer le serveur d'outils, lister ses outils au format attendu par le LLM et les appeler.
- **Options** : `langchain-mcp-adapters` (convertit en outils LangChain) ; le `mcp.Client` du SDK.
- **Choix** : `ToolBox` (≈ 80 lignes) : `mcp.Client(StdioServerParameters(...))` lance `python -m hello_support.mcp_server` avec `HS_SCENARIO`, convertit `list_tools()` au format OpenAI `tools` (le schéma JSON MCP est repris tel quel) et décode les résultats. Une liste est renvoyée en `structured_content` = `{"result": [...]}` ou en un bloc texte par élément. Le même `ToolBox` accepte un serveur **en mémoire** pour les tests.
- **Pourquoi** : sans LangChain dans la boucle (D-05), l'adaptateur n'apporte rien. Le SDK direct montre ce que fait réellement un hôte MCP : *spawn, handshake, list, call*.
- **Compromis** : il faut gérer soi-même le décodage des résultats. Un premier bug (liste renvoyée en plusieurs blocs) a été trouvé à la première exécution réelle.
- **Compétence visée** : MCP, tool integration.

D-21 — Validation : 6 cas exécutables avec vérifications automatiques

- **Date** : 2026-10-02 · **Jalon** : J4

- **Besoin** : savoir si le système « marche » sur les cas de la spec, le révéfier après chaque changement de prompt ou de modèle, et comparer deux modèles sur la même base.
- **Options** : (a) relire les réponses à la main ; (b) **LLM-as-a-judge** (un modèle note les réponses) ; (c) **vérifications déterministes** sur l'état final (route, outils appelés, résultats, mots-clés et citations de la réponse) ; (d) un framework d'évaluation (Ragas, DeepEval...).
- **Choix** : (c), dans `cases.py` : 6 cas, de 5 à 7 vérifications nommées chacun (ex. « statut observé = stopped », « aucun appel de statut », « dernier incident lu (ORDER BY...) », « citations exactes », « en français »).
Commande `hello-support bench` : N exécutions × modèles, rapport Markdown (`docs/bench/`) avec **toutes les réponses**, et JSON brut (`runs/`). Les tests unitaires (pytest) vérifient le code avec un LLM **scripté** ; le `bench` vérifie le système avec les **vrais** modèles.
- **Pourquoi** : c'est reproductible, gratuit et explicable. Une vérification qui échoue désigne un défaut précis. Le `bench` a immédiatement révélé deux défauts invisibles en démo (D-22, D-23). Un juge LLM local (4–7 B) serait moins fiable que les réponses qu'il note, et un framework ajouterait des dépendances pour 6 cas.
- **Compromis** : les vérifications par mots-clés sont **grossières**. Une bonne réponse peut échouer (formulation imprévue), une mauvaise peut passer. Elles ne mesurent pas la qualité du conseil. D'où la conservation des réponses complètes pour relecture humaine. 6 cas ne font pas une évaluation statistique.
- **Compétence visée** : Prototype → production, evaluation.

D-22 — Post-traitement déterministe : citations normalisées + mention de simulation

- **Date** : 2026-10-02 · **Jalon** : J4 · **Décision issue d'un échec mesuré**
- **Constat** (`bench J4, 7 B`) : malgré la consigne « copier les étiquettes exactement », le modèle écrit `postgres_connection.md#Service_status` (underscore). Il omet aussi la mention « simulé » exigée par C1.
- **Options** : renforcer encore le prompt ; changer le format des identifiants ; **post-traiter la réponse dans le code**.
- **Choix** : `postprocess.py` :
 - `normalize_citations` ramène chaque citation `doc.md#Section` à l'identifiant canonique de la base (insensible à la casse et aux `_`) et signale les citations inconnues dans la trace, sans les supprimer ;
 - `simulation_footer` ajoute en fin de réponse une ligne construite **à partir des résultats d'outils** : « Statut observé en simulation (scénario « stopped ») : postgres = stopped. Aucune action corrective n'a été exécutée. » La phrase est en français si la question l'est.
- **Pourquoi** : c'est le même principe que D-17. Ce que le code **sait** (le statut vient d'une simulation, rien n'a été exécuté, la liste des sections existantes), le code le dit, au lieu d'espérer que le modèle le dise. Ça rend la réponse vérifiable et conforme à la réponse attendue du document initial.
- **Compromis** : la vérification « dit simulé » de C1 est désormais satisfaite **par construction**. Elle teste le système, pas le modèle, et il faut le dire. La détection de langue est une heuristique (mots-outils français).
- **Compétence visée** : Reliability.

D-23 — Questions de données : toutes les requêtes dans la même étape

- **Date** : 2026-10-02 · **Jalon** : J4 · **Décision issue d'un échec mesuré**
- **Constat** : au cas C4 (« combien... et le dernier est-il résolu ? »), le 7 B a exécuté un `COUNT(*)`, puis il a écrit « Now let's check the status of the last incident » et **inventé** la réponse au lieu d'appeler l'outil une 2^e fois. Une version antérieure concluait à partir d'un `MAX(resolved)` qui ne permet pas de répondre.
- **Choix** : la consigne `history` demande **toutes les requêtes dans la même étape** (appels d'outils parallèles), une requête par partie de la question, avec l'exemple `ORDER BY started_at DESC LIMIT 1`. Elle interdit aussi de décrire une requête non exécutée. La vérification C4 contrôle qu'une requête lisant le dernier incident a bien été **exécutée**.
- **Pourquoi** : le modèle hallucine quand il « raconte » l'étape suivante au lieu de la faire. Faire planifier les requêtes d'un coup supprime cette étape intermédiaire. Résultat mesuré : 2 requêtes émises en parallèle, conclusion « 3 incidents, le dernier non résolu » **déduite des lignes renvoyées**.

- **Compromis** : ça repose sur l'aptitude du modèle aux appels parallèles. Une question nécessitant une requête dépendant du résultat d'une autre (vraie analyse en plusieurs temps) ne serait pas couverte : il faudrait alors un plan explicite ou un budget d'étapes plus grand.
- **Compétence visée** : Enterprise data agents.

D-24 — Triage : règles explicites + exemples, mesurés sur des paraphrases tenues à l'écart

- **Date** : 2026-10-02 · **Jalon** : J4 · **Décision issue d'un échec mesuré**
- **Constat** (bench J4 n° 1) : le SLM classait « Mon application ne parvient plus à se connecter à PostgreSQL. Que dois-je vérifier ? » en documentation **3 fois sur 3**. Il n'observait donc jamais le statut, d'où C1/C2 = 0/3. Ajouter seulement des exemples (*few-shot*) a corrigé le SLM sur les paraphrases, mais **dégradé le 7 B** : « Mon Kafka est lent » → `malfunction/nginx`, « My MongoDB replica set is down » → `malfunction/redis`. C'est dangereux, puisqu'il observerait un service sans rapport avec la question.
- **Choix** : prompt de triage = définitions + **2 règles explicites** (un autre produit cité → `out_of_scope`, jamais mappé sur un service connu ; une panne vécue maintenant → `malfunction`, même si la phrase finit par « que vérifier ? ») + **6 exemples** formulés différemment des questions du bench.
- **Mesure** : 12 questions = les 6 du bench + **6 paraphrases tenues à l'écart** (jamais vues pendant le réglage) : **12/12 pour les deux modèles**, contre 11/12 (SLM) et 10/12 (7 B) avec les seuls exemples.
- **Pourquoi** : un exemple sans règle peut être sur-généralisé (le 7 B a appris « produit inconnu ⇒ choisir un service connu »). La règle fixe la limite, les exemples montrent le format. Tester sur des paraphrases non vues évite de régler le prompt pour les seules questions du bench (sur-ajustement).
- **Compromis** : 12 questions restent un petit échantillon. Chaque modification de prompt doit être re-mesurée, car un gain sur un modèle peut être une perte sur l'autre (cas observé ici).
- **Compétence visée** : Evaluate AI tech, SLMs.

D-25 — ADR : modèle par défaut = Qwen2.5-7B-Instruct ; le SLM reste une option mesurée

- **Date** : 2026-10-02 · **Jalon** : J5 · **Statut** : Acceptée. Elle confirme D-04 avec des mesures.
- **Contexte** : deux modèles servis localement par LM Studio, mêmes prompts, même code, 6 cas × 3 exécutions (BENCH J4), plus une mesure de débit du serving (BENCH J5).
- **Options** : (a) SLM Qwen3-4B-Instruct-2507 par défaut ; (b) **7 B par défaut** ; (c) hybride : SLM pour le triage (tâche étroite, sortie contrainte), 7 B pour la réponse.
- **Données** :

Critère	SLM 4 B	7 B
Cas réussis (6 × 3)	15/18	18/18
Défaut grave observé	invente des identifiants de source quand un outil échoue (C6, 3/3)	présente parfois les symptômes de la fiche comme des « logs observés » (non détecté par les vérifications)
Triage (12 questions dont 6 tenues à l'écart)	12/12	12/12
Latence p50 par requête (à chaud)	6,0 s	9,0 s
Débit de génération, 1 requête à la fois	107 tokens/s	71 tokens/s
Débit agrégé, 4 requêtes concurrentes	173 tokens/s	128 tokens/s
VRAM (Q4_K_M)	~2,5 Go	~4,7 Go
Coût estimé si API (gpt-4o-mini / Haiku 4.5), /1000 req.	~0,62 \$ / ~4,5 \$	~0,62 \$ / ~4,6 \$

- **Décision** : (b) 7 B par défaut (HS_MODEL_DEFAULT=large). Le SLM reste sélectionnable (--model s1m) et c'est le meilleur candidat pour le triage si la latence devient prioritaire.
- **Pourquoi** : sur un assistant de support, une **source inventée** est plus grave qu'une réponse plus lente de 3 s. Le SLM est plus rapide sur tous les indicateurs (~1,5×) et aussi bon au triage. Il ne perd que sur la robustesse en cas d'erreur d'outil, mais c'est le cas qui compte en production. Le coût **local** est nul dans les deux cas, et le coût cloud estimé est identique, car les tokens sont surtout en entrée (contexte du RAG) et les volumes sont proches. La taille du modèle ne change donc pas la facture : c'est la longueur du contexte qui compte.
- **Conséquences / suite** : (c) est la prochaine expérience logique : triage par le SLM, réponse par le 7 B. Il faudrait la mesurer avec le même bench avant de l'adopter. Avec un modèle plus grand (cloud), la plupart des garde-fous resteraient utiles : ils protègent contre des classes d'erreurs, pas contre un modèle précis.
- **Compétence visée** : LLMs & SLMs, latency/cost, evaluate → plan.

D-26 — Méthode de mesure : latence, débit, coût

- **Date** : 2026-10-02 · **Jalon** : J5
- **Besoin** : parler de latence, de débit et de coût avec des **chiffres mesurés** et une méthode qu'on peut expliquer.
- **Choix** :
 - **latence** : par requête et à chaud (session MCP et modèle déjà chargés), p50/max sur 18 requêtes par modèle. Le **démarrage à froid** (20–26 s : torch, modèles d'embedding, Chroma, chargement LM Studio) est mesuré à part, parce qu'il se paie une fois par session ;
 - **décomposition** par la trace : temps LLM, temps des outils, nombre d'appels ;
 - **débit** : (1) débit de génération dans le bench (tokens produits / temps LLM, prompt compris) ; (2) hello-support throughput : la même requête répétée 8 fois à concurrence 1 puis 4, pour mesurer le débit agrégé (tokens/s, requêtes/min) et la latence individuelle ;
 - **coût** : local = 0 € (électricité non comptée). Cloud = **estimation** : tokens in/out moyens mesurés × prix publics indicatifs, sans compte ni appel, avec des prix à revérifier avant de les citer.
- **Résultats marquants** :
 - ~2 600–2 800 tokens en entrée pour ~350–390 en sortie par requête : le **contexte** (prompts, passages du RAG, résultats d'outils) domine le coût, donc c'est là qu'il faut optimiser ;
 - la concurrence 4 multiplie le débit agrégé par 1,6–1,8, mais double la latence individuelle : c'est le compromis débit / latence classique du serving ;
 - le chargement du RAG (~14–27 s) est le premier poste de la latence à froid.
- **Compromis** : une seule machine, peu d'exécutions, température 0 : pas de vraie distribution statistique. Le débit est mesuré sur LM Studio, pas sur un serveur de production (vLLM, batching continu : « pour aller plus loin »). Les prix évoluent.
- **Compétence visée** : Latency, throughput, cost.

D-27 — Structure du code

- **Date** : 2026-10-02 · **Jalon** : J5 (bilan)
- **Choix** : un package src/hello_support/ en modules à responsabilité unique :

Module	Rôle	Dépend de
cli.py	commandes smoke, search, ask, bench, throughput, affichage	tout le reste (imports tardifs)
workflow.py	graphe LangGraph, état, export des traces	agents, toolbox, postprocess
agents.py	trriage, prompts, politique d'outils, boucle bornée	llm, toolbox
llm.py	client OpenAI-compatible, mesures	openai
toolbox.py	hôte MCP (spawn, list, call)	mcp
mcp_server.py	serveur MCP, 3 outils	retrieval, data_store, sql_guard

Module	Rôle	Dépend de
retrieval.py	découpage, embeddings, Chroma, reranking	torch, sentence-transformers, chromadb
sql_guard.py / data_store.py	SQL lecture seule ; données simulées et SQLite	stdlib
postprocess.py	citations, mention de simulation	retrieval (liste des sections)
cases.py / benchmark.py	cas de validation, mesures, rapports	workflow
config.py	variables d'environnement	python-dotenv

- **Pourquoi** : la frontière **MCP** sépare physiquement les agents (processus hôte) des outils et des données (sous-processus) : les agents ne savent pas comment un outil est fait. Les dépendances lourdes (torch, Chroma) ne sont chargées que par le serveur d'outils et la commande search. Les tests et la CLI restent rapides. Code, prompts et commentaires sont en anglais, la documentation en français.
- **Compromis** : ~1 600 lignes de code (+ ~400 de tests) pour un « hello world », dont une bonne part de garde-fous et de mesure. Les prompts sont des constantes Python, pas des fichiers versionnés à part.
- **Compétence visée** : Software architecture, Python.

D-28 — Stratégie de tests

- **Date** : 2026-10-02 · **Jalon** : J5 (bilan)
- **Choix** : trois niveaux.
 1. **Unitaires, hors ligne, < 3 s** (uv run pytest, 40 tests) : découpage des fiches, garde-fous SQL (refus de DELETE / DROP / PRAGMA / ATTACH / load_extension, limite de lignes), contrats MCP via un **client MCP réel connecté en mémoire**, boucle d'agent et graphe complet avec un **LLM scripté** (budgets, déduplication, dernier appel sans outils, relance quand un outil exigé est ignoré, erreur d'outil), post-traitement, vérifications des cas.
 2. **Intégration avec modèles** (pytest -m models) : RAG de bout en bout sur GPU.
 3. **Système avec les vrais LLM** (hello-support bench) : 6 cas × N × modèles, vérifications automatiques et réponses archivées.
- **Pourquoi** : ce qui est déterministe (garde-fous, contrats, orchestration) est testé de façon déterministe. Ce qui dépend du modèle est **mesuré**, pas « testé vert ». Le LLM scripté permet de reproduire exactement les comportements fautifs observés (réponse sans l'outil exigé, 46 appels dupliqués) et de verrouiller les correctifs.
- **Compromis** : pas de CI (hors périmètre). Le bench n'est pas lancé automatiquement : il faut LM Studio et ~6 min. Les vérifications par mots-clés restent grossières (D-21).
- **Compétence visée** : Production-grade, reliability.

D-29 — Agents, routeur et code : qui décide quoi, et pourquoi aucune boucle entre agents

- **Date** : 2026-10-04 · **Jalon** : documentation (aucun changement de comportement)
- **Besoin** : rendre la nature de chaque bloc lisible. Un lecteur du schéma demandait : « s'il y a des agents, où sont les boucles ? », « le triage est-il un agent ? ».
- **Constat (code)** :
 - **Agents** = Documentaliste et Technicien. run_agent fait boucler le LLM sur les outils : le modèle choisit l'outil et ses arguments, le code l'exécute et renvoie le résultat. La boucle fait ≤ 3 appels LLM (MAX_LLM_CALLS), le dernier sans outils, ≤ 3 appels d'outil par étape. Un outil exigé est relancé une fois si le modèle l'a ignoré, et la boucle s'arrête dès une réponse texte.
 - **Triage = routeur** : 1 appel LLM en response_format JSON Schema (intent, service), sans outil ni boucle. Le code en tire la branche du graphe et la politique d'outils (D-17).
 - **Code déterministe** : contrôles de la boucle (D-18), post-traitement (D-22), reclassement d'une panne sans service connu en vague.

- **Options** : (a) un graphe multi-agents avec retours (le technicien peut renvoyer au documentaliste, ou un superviseur ré-arbitre) ; (b) **un graphe linéaire, les boucles restant à l'intérieur des agents.**
- **Choix** : (b). Chaque nœud LangGraph s'exécute au plus une fois par question.
- **Pourquoi** : le besoin est séquentiel : trouver les sources, puis diagnostiquer. Un retour entre agents ajouterait des appels LLM (latence, tokens), un risque de ping-pong, et un comportement plus difficile à tester et à borner, sans gain mesuré sur les 6 cas. Les boucles internes suffisent pour corriger une requête ou un appel d'outil raté. Les limites (3 appels LLM, budgets d'outils, `recursion_limit=10`) garantissent l'arrêt.
- **Compromis** : si les passages trouvés sont mauvais, le technicien ne peut pas demander une nouvelle recherche. Il le signale dans sa réponse. Une boucle documentaliste ↔ technicien, ou un superviseur, serait l'évolution naturelle, à mesurer avec le même bench.
- **Représentation** : schémas avec légende (agent , routeur , code , outil MCP , modèle ) et zoom sur la boucle d'un agent (README, synthèse ci-dessus, SPEC §4).
- **Compétence visée** : AI agents, agent orchestration, workflow execution.